Le pedigree du VC est-il une garantie d'exit ?

Analyse comparative Top 10 VCs vs marché
CrunchBase 2003–2013 · 9 562 acquisitions

Hypothèses de travail

H1. Le taux d'exit diffère entre startups Top VC et startups du marché.

H2. Le délai et la valorisation d'exit varient selon le type d'investisseur.

H3. Après 2008, le cycle macro modifie cette relation.

Code & données

Dataset : acquisitions.csv, objects.csv, funding_rounds.csv (CrunchBase), disponibles sur le jeu de données public Kaggle Startup Investments.
www.kaggle.com/datasets/justinas/startup-investments/data

Code : requêtes SQL et traitements Python (pandas) documentés sur GitHub.
github.com/Elias-Mld

Elias Milandou

Data Analyst · 24 mars 2026

Résumé exécutif

En venture capital, la question la plus difficile n'est pas de lever des fonds, mais d'obtenir un exit dans de bonnes conditions. Pour un fondateur, cela signifie transformer des années de risque en liquidité. Pour un investisseur, cela signifie convertir un portefeuille en retours distribuables. Dans ce contexte, une croyance domine le marché : le pedigree du VC améliorerait mécaniquement la probabilité, la vitesse et le prix de sortie.

Ce rapport examine cette hypothèse sur CrunchBase, sur la période 2003 à 2013, en comparant 2,779 startups financées par les 10 VCs les plus actifs du dataset, à 18,828 startups financées par le reste du marché. L'objectif n'est pas de revendiquer une causalité stricte, mais d'apporter une lecture opérationnelle : dans quelle mesure le choix de l'investisseur est-il associé à de meilleures conditions d'exit, et sur quelle dimension l'écart est-il le plus marqué.

Le choix de cette fenêtre temporelle est délibéré. La décennie 2003 à 2013 couvre un cycle macroéconomique complet : phase d'expansion, crise financière de 2008 et reprise post-crise. Elle offre le recul nécessaire pour observer des exits réellement consommés, pas des valorisations latentes. Les fonds actifs sur cette période ont eu le temps de liquider intégralement leurs positions, ce qui élimine le biais de « paper returns » qui fausse toute analyse sur des millésimes récents. Analyser des données de 2020 ou 2023 reviendrait à comparer des exits réalisés à des promesses de rendement encore inscrites au bilan. Cette base CrunchBase, figée en 2013, constitue donc un terrain d'observation propre, où chaque exit est documenté et définitif.

Cadre de lecture

Le label « Top VC » désigne ici les dix investisseurs les plus actifs par volume de deals dans CrunchBase, pas les plus performants en rendement financier. C'est un proxy d'empreinte sur le marché, pas de qualité. Trois métriques structurent l'analyse : (1) la probabilité d'exit, (2) le délai jusqu'à l'exit, (3) le prix d'acquisition. Ce triptyque évite l'erreur classique qui consiste à confondre vitesse et création de valeur. Un exit rapide n'est pas nécessairement un bon exit ; un exit cher n'est pas nécessairement reproductible.

×1,76
taux d'exit Top VCs vs marché

2,75 ans
délai médian exit Top VCs

$95M
prix médian exit Top VCs

1,26 ans
délai record 500 Startups

En 2003, un investisseur cherchant à maximiser ses chances d'exit avait peu de données pour choisir son VC. Le marché VC américain investissait alors ~19 milliards de dollars par an, répartis entre des centaines de fonds aux stratégies hétérogènes. La question centrale restait sans réponse empirique : le nom du VC qui vous finance change-t-il réellement vos chances de sortir, et à quel prix ?

L'analyse de 9 562 acquisitions documentées sur CrunchBase, entre 2003 et 2013, fait ressortir deux effets principaux et un effet secondaire. D'abord, les startups Top VC affichent un taux d'exit plus élevé, 16,7 % contre 9,5 % pour le marché, soit un ratio de ×1,76. Ensuite, le prix d'exit est supérieur, avec une médiane plus haute ($95M contre $77M) et un écart qui se creuse dans le haut de distribution (P90 : $763M contre $424M). Enfin, l'avantage de délai est plus modeste, 2,75 ans contre 3,04 ans, soit environ 3,48 mois.

L'insight le plus contre-intuitif de cette analyse concerne les accélérateurs. 500 Startups et Y Combinator sortent en médiane 1,26 et 1,52 ans respectivement, deux fois plus vite que Sequoia Capital (3,42 ans). Cette vitesse apparente masque une réalité différente : ces exits rapides sont majoritairement des acqui-hires à $10–30M, pas des acquisitions à $100M+. Il ne s'agit pas d'une meilleure performance au sens universel, mais de modèles d'investissement fondamentalement distincts, optimisés pour des objectifs incomparables.

En synthèse, le pedigree VC n'est pas une garantie, mais un filtre de qualité dont l'effet varie selon le modèle d'investissement. Pour un analyste ou un fondateur, la bonne question n'est pas "quel VC a le meilleur pedigree", mais "quel modèle d'exit ce VC privilégie". Les données invitent à distinguer la vitesse de sortie, la valeur de sortie, et la probabilité de sortie, trois métriques qui racontent des histoires différentes.

01 Le pedigree VC est associé à un taux d'exit 1,76 fois plus élevé

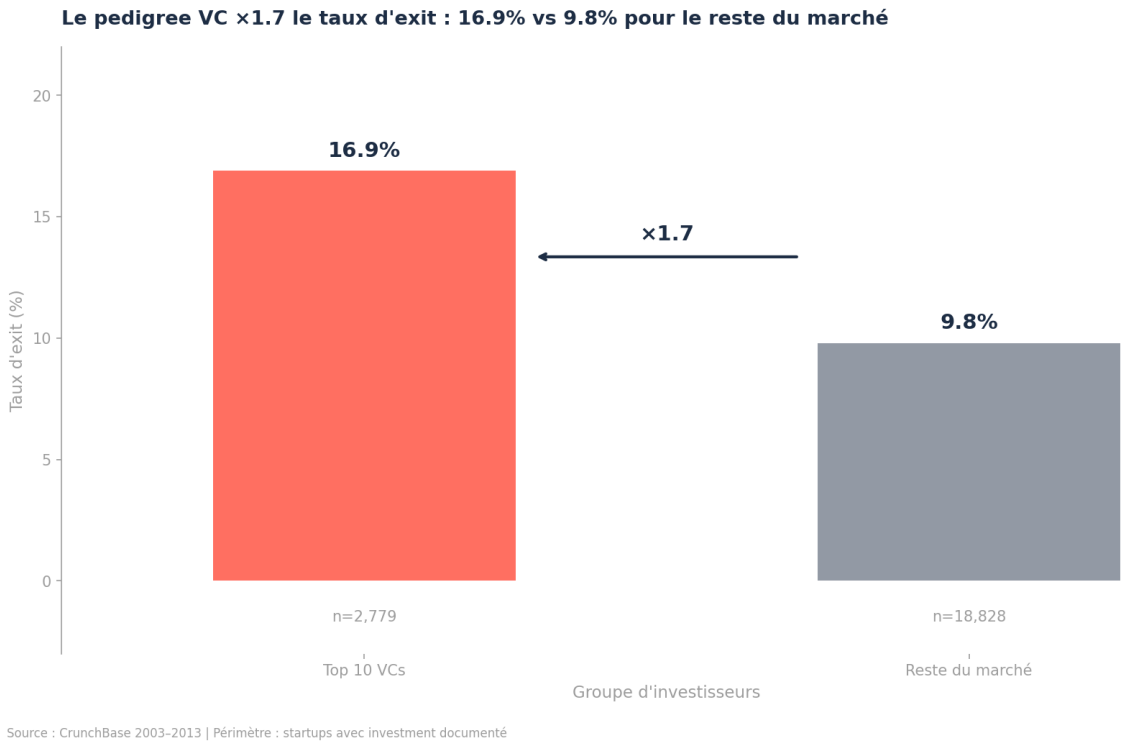

Figure 1. Top 10 VCs vs marché, n = 2,779 et n = 18,828, CrunchBase 2003 à 2013

Sur l'ensemble de la période 2003 à 2013, 16,7 % des startups financées par l'un des dix plus grands VCs du dataset ont été acquises, contre 9,5 % pour le reste du marché. Ce ratio de ×1,76 constitue le premier signal fort de l'analyse. Sur 2,779 startups Top VC identifiées dans le dataset, 463 ont un exit documenté, contre 1794 pour les 18,828 startups du marché général.

Il serait tentant de conclure que le VC "crée" cet avantage. La réalité est plus nuancée. Les Top VCs sélectionnent ex ante les startups les plus prometteuses, celles qui auraient peut-être été acquises même sans eux. Ce biais de sélection circulaire est impossible à corriger sans données contrefactuelles. De plus, le biais du survivant est omniprésent : seules les startups avec un exit documenté apparaissent dans ce calcul. Les centaines de startups financées par des Top VCs et ayant fait faillite sont invisibles dans ce ratio.

Malgré ces réserves, l'écart observé reste économiquement significatif. La lecture correcte est corrélationnelle : les startups associées aux Top VCs sortent plus souvent, sans que ce résultat suffise à démontrer un effet causal pur du VC. Pour un fondateur ou un LP, la conclusion utile est pragmatique : le label Top VC fonctionne, au minimum, comme un signal de crédibilité sur le marché des acquéreurs.

02 L'avantage sur le délai existe, mais il reste modeste (0,29 an)

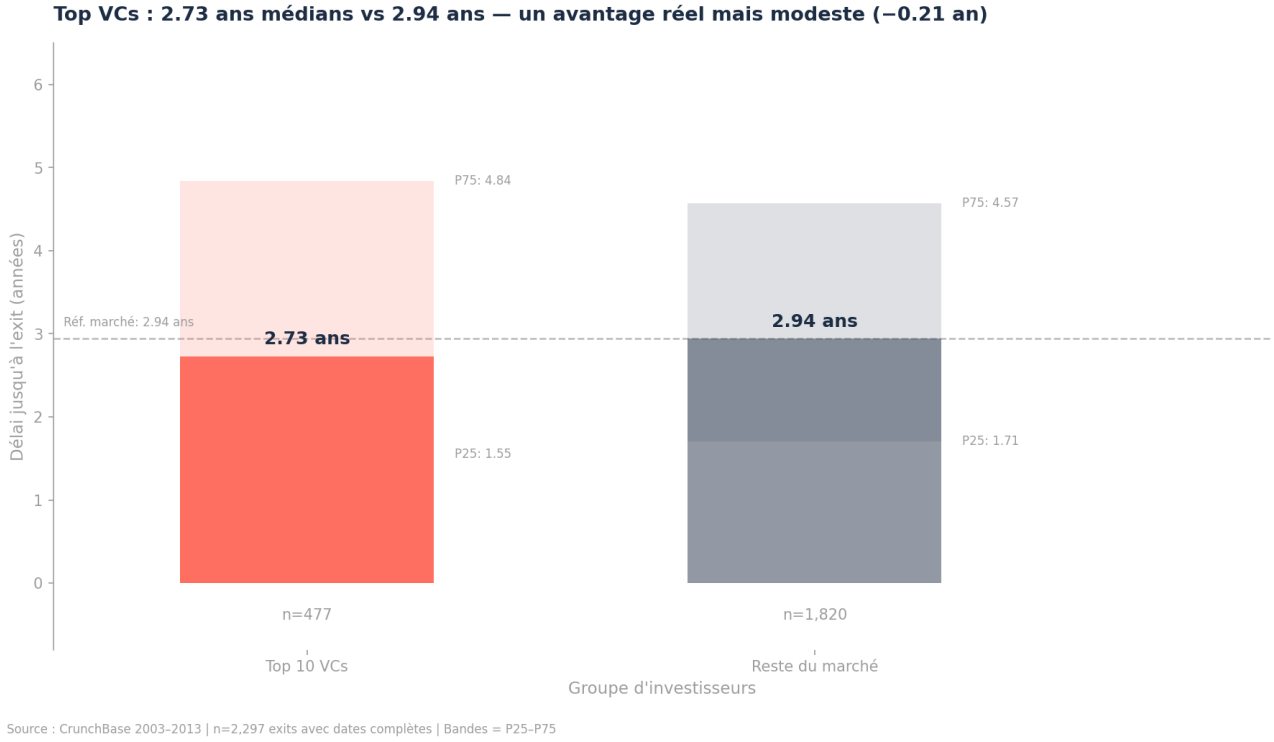

Figure 2. Délai d'exit (médiane, P75), Top VCs vs marché, n = 475 et n = 1820

Le délai médian d'exit des startups Top VC est de 2,75 ans après leur premier tour de financement, contre 3,04 ans pour le marché général. L'écart absolu est de 0,29 an, soit environ 3,48 mois. Statistiquement réel sur n=2,295 observations, cet avantage reste limité : dans les faits, peu de décideurs choisissent un VC pour gagner seulement quelques mois.

La queue de distribution est instructive. Le P75 des startups Top VC (4,93 ans) est supérieur au P75 du marché (4,63 ans). Les exits longs Top VC s'étirent donc davantage que la moyenne du marché. Ce résultat reflète l'hétérogénéité du groupe : les accélérateurs tirent la médiane vers le bas, tandis que les fonds institutionnels orientés deep tech l'étirent vers le haut.

L'implication analytique est claire : sélectionner les meilleures startups n'est pas équivalent à accélérer leur développement opérationnel. Un Top VC peut identifier une startup à fort potentiel sans pour autant réduire le temps nécessaire à sa maturation. L'avantage comparatif des Top VCs se joue davantage sur la valorisation à la sortie que sur la vitesse de sortie.

03 Prix d'exit médian : écart d'environ 23 % entre le groupe Top VC et le marché

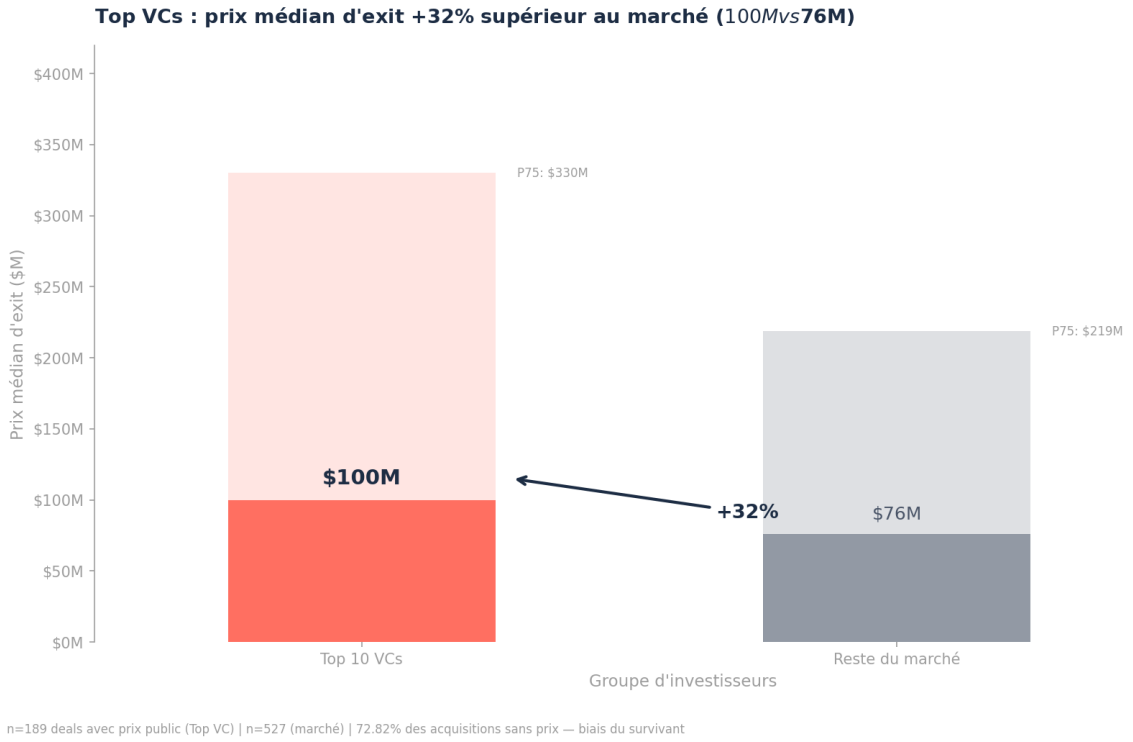

Figure 3. Prix d'exit (médiane, P75, P90), Top VCs vs marché, n = 189 et n = 527 exits avec prix

Le prix médian d'exit des startups Top VC ($95M) est 1,23 fois supérieur à celui du marché ($77M). C'est l'effet le plus net de cette analyse. Mais c'est dans les queues de distribution que l'avantage devient spectaculaire : au P75, le rapport passe à ×1,47 ($324M vs $220M) ; au P90, il atteint ×1,8 ($763M vs $424M). Les Top VCs ne se contentent pas de sortir plus cher en médiane, ils concentrent une proportion disproportionnée des mega-exits.

Cette observation doit être interprétée avec le biais le plus critique du dataset. Seuls 39,8 % des exits Top VC ont un prix renseigné (189 sur 475), contre 29 % pour le marché (527 sur 1820). Les prix manquants ne sont pas aléatoires : les petits deals, les acqui-hires discrets, et les acquisitions confidentielles sont moins souvent publiés. Le sous-échantillon avec prix est donc orienté vers les exits médiatisés. Si l'ensemble des transactions était documenté, les médianes réelles seraient probablement plus basses dans les deux groupes.

Malgré ce biais, l'écart entre les groupes reste cohérent avec la logique économique : les acquéreurs stratégiques qui rachètent des startups Top VC paient souvent une prime de marque. Le réseau de l'investisseur facilite l'accès à des acquéreurs à forte capacité de paiement. Ce n'est pas seulement la qualité intrinsèque de la startup, c'est aussi la qualité du processus de cession piloté par le VC.

04 Accélérateurs vs VCs : deux modèles, deux temporalités

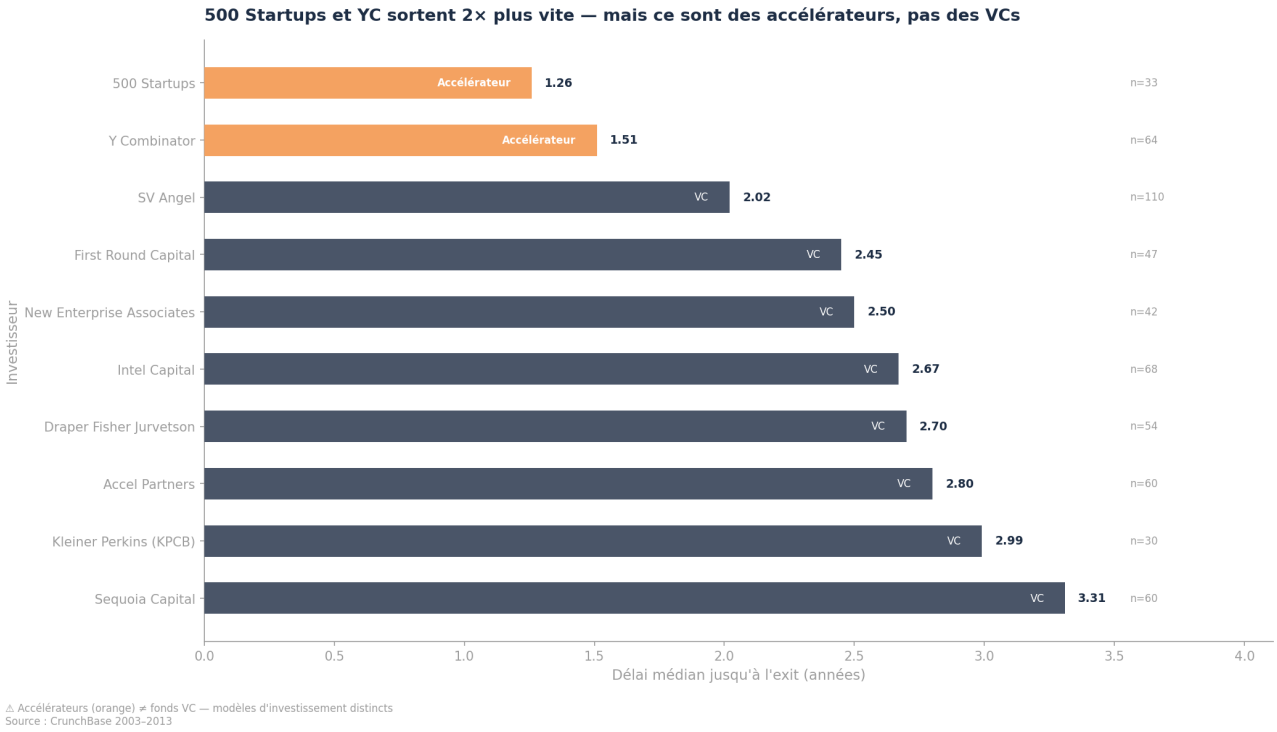

Figure 4. Délai médian d'exit par investisseur, classement du plus rapide au plus lent

Le classement des Top VCs par délai médian d'exit met en évidence deux modèles d'investissement. D'un côté, les accélérateurs : 500 Startups (1,26 an) et Y Combinator (1,52 an), qui orientent vers des sorties rapides. De l'autre, les fonds institutionnels : Sequoia Capital (3,42 ans), Kleiner Perkins (2,76 ans) et Accel Partners (2,83 ans), avec des cycles de création de valeur plus longs. Entre ces deux pôles, SV Angel (2,02 ans) et First Round Capital (2,45 ans) occupent une position intermédiaire.

Cette différence de rythme ne traduit pas une différence de qualité, mais une différence de stratégie. Un accélérateur recherche une montée en traction rapide et multiplie les paris précoces. Un fonds institutionnel investit davantage de capital et accompagne des trajectoires de maturité plus longues, souvent sur des dossiers technologiques plus complexes. Comparer les délais d'exit sans intégrer la valeur de sortie conduit à une lecture incomplète.

05 Prix d'exit par VC, Accel et Sequoia robustes, NEA et KPCB à interpréter avec prudence

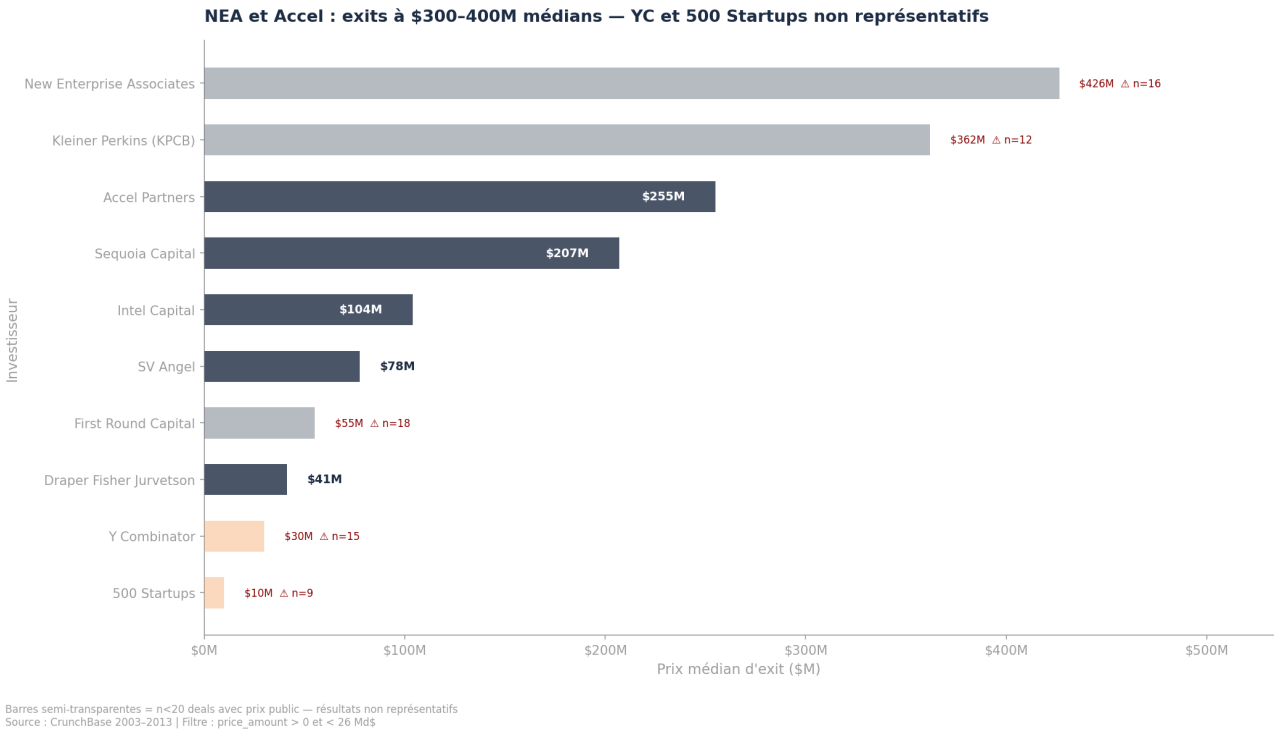

Figure 5. Prix médian d'exit par investisseur, n < 20 pour NEA, KPCB, First Round, YC, 500 Startups

Le classement par prix médian d'exit révèle deux pôles. D'un côté, les fonds institutionnels généralistes tech : Accel Partners ($210M, n=26) et Sequoia Capital ($207M, n=39) affichent les données les plus solides statistiquement parmi les VCs à prix médian élevé. De l'autre, les accélérateurs confirment leur modèle : YC ($30M, n=15) et 500 Startups ($10M, n=9) sortent moins cher, et beaucoup plus rapidement, comme vu en Section 4.

Contexte, accélérateur vs VC institutionnel

Y Combinator, fondé en 2005, et 500 Startups, fondé en 2010, illustrent une rupture par rapport au modèle VC classique. Là où un fonds institutionnel investit des tickets élevés sur un horizon long, un accélérateur multiplie les petits tickets en phase très précoce, avec un horizon de sortie plus court. Ce cadre explique des délais structurellement plus courts et des prix d'exit plus faibles, sans que cela implique une moindre pertinence économique du modèle.

NEA ($443M) et Kleiner Perkins ($400M) dominent le classement brut, mais leurs n<20 exits avec prix renseigné les rendent statistiquement fragiles. Ces valeurs sont indicatives. Quelques transactions emblématiques peuvent tirer ces indicateurs vers le haut ; elles ne reflètent pas nécessairement le comportement médian du portefeuille.

Intel Capital ($104M, n=29) mérite une attention particulière. En tant que corporate VC, Intel Capital n'optimise pas uniquement le rendement financier, il investit dans l'écosystème stratégique d'Intel (semiconducteurs, cloud, IoT). Ses exits reflètent souvent une valeur stratégique pour Intel elle-même plutôt qu'une valorisation de marché pure. Comparer Intel Capital à Sequoia sur le seul critère du prix

médian d'exit revient donc à comparer des stratégies d'investissement différentes.

06 Après 2008, les délais d'exit augmentent pour tous, l'avantage Top VC apparaît surtout en relatif

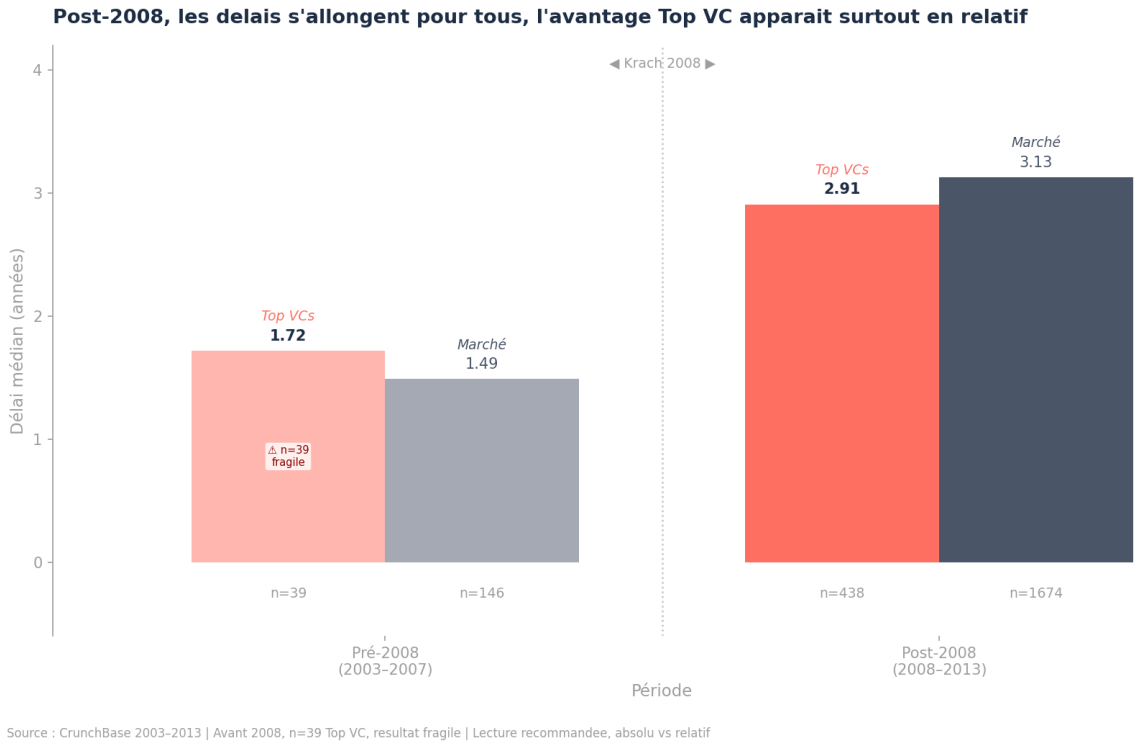

Figure 6. Délai médian d'exit, avant 2008 vs après 2008, n = 39 Top VC avant 2008

La crise financière de 2008 a modifié durablement la dynamique des exits sur le marché VC. Dans un environnement plus contraint, les acquéreurs sont devenus plus sélectifs, les valorisations se sont ajustées, et les cycles de négociation se sont allongés. Après 2008, la médiane d'exit Top VC atteint 2,94 ans, et le marché général 3,21 ans, contre 1,72 ans et 1,5 ans avant 2008.

Le point clé consiste à distinguer performance absolue et performance relative. En absolu, le marché se dégrade après la crise, les délais augmentent pour les deux groupes. En relatif, l'avantage Top VC apparaît surtout après 2008, avec 2,94 ans contre 3,21 ans pour le marché, soit 0,27 an d'écart. Avant 2008, la relation est inversée, mais avec un volume Top VC très réduit ; l'interprétation doit donc rester prudente.

L'implication pour un board ou un investisseur est directe. Le pedigree VC ne signifie pas une accélération automatique des exits ; il semble surtout amortir la dégradation en période de stress macroéconomique. Autrement dit, la valeur du Top VC apparaît comme plus défensive en phase adverse, via l'accès aux acquéreurs, la crédibilité du process de cession, et la capacité à préserver des options de sortie.

Une réserve méthodologique s'impose. Le volume de données CrunchBase a augmenté de +147 % après 2008, probablement dû à l'expansion de la communauté contributrice, pas à une hausse équivalente du marché réel. Avec n=39 Top VC pré-2008, tout résultat sur cette période doit être interprété avec la plus grande précaution. La comparaison pré/post 2008 est une piste analytique valide, pas une conclusion définitive.

Conclusion

Ce travail répond à une question de décision, pas à une question académique abstraite : faut-il privilégier un VC de pedigree pour améliorer ses conditions d'exit ? Les données suggèrent oui, mais de manière ciblée. L'effet est fort sur la probabilité d'exit (×1,76) et sur la valeur de sortie (médiane +23 %, P90 +80 %), et beaucoup plus modeste sur la vitesse (3,48 mois). En pratique, le pedigree semble surtout améliorer l'accès à des acquéreurs capables de payer davantage, plutôt que raccourcir massivement le temps de maturation de l'entreprise.

Pour un fondateur, la grille d'arbitrage devient plus claire. Si l'objectif prioritaire est la rapidité de liquidité, un modèle accélérateur peut être cohérent. Si l'objectif est la valeur d'exit, les fonds institutionnels robustes dans le dataset (notamment Accel et Sequoia sur n>=20) offrent un profil plus pertinent. Pour un LP, l'implication est symétrique, comparer des fonds sans expliciter leur modèle d'exit cible revient à comparer des stratégies non comparables.

Ce qu'il faut faire maintenant

1) Définir ex ante la métrique cible (vitesse, probabilité, valeur). 2) Évaluer les VCs contre cette métrique, pas sur leur notoriété seule. 3) Segmenter systématiquement accélérateurs et fonds institutionnels dans toute analyse comparative. 4) Suivre les performances avec des cohortes et des métriques de fonds (DPI/TVPI) pour valider la robustesse du signal.

Ces résultats ne doivent toutefois pas être sur-interprétés causalement. Le biais de sélection circulaire (les meilleurs VCs choisissent déjà les meilleurs dossiers), le biais survivant (faillites invisibles), le manque de prix documentés (~72,82 % manquants), et l'absence d'information sur le lead investor limitent fortement l'inférence causale. La bonne posture analytique est donc la suivante : considérer ce rapport comme un signal directionnel robuste, utile pour orienter les décisions, mais insuffisant pour conclure à lui seul sur l'effet causal exact de chaque VC.

Pour renforcer encore l'utilité opérationnelle, l'étape suivante consiste à structurer une lecture par cohortes annuelles de startups, puis à suivre les sorties à horizon fixe, par exemple 3 ans, 5 ans et 7 ans. Cette approche permettrait de mieux isoler l'effet du cycle macroéconomique de l'effet de sélection des investisseurs, et de comparer les modèles sur une base temporelle homogène. Elle clarifierait surtout la question clé des comités d'investissement : quel couple probabilité, valeur, délai est réellement reproductible selon le type de VC.

En synthèse, la décision n'est pas de choisir le VC le plus prestigieux ; elle consiste à choisir le partenaire dont le mode de création de valeur est cohérent avec la trajectoire de l'entreprise. Un accélérateur optimise souvent la vitesse de mise sur le marché et la probabilité de premiers exits de petite taille ; un fonds institutionnel optimise plus fréquemment la profondeur de valeur et l'accès aux acquéreurs stratégiques capables de payer une prime. La vraie discipline, pour un fondateur comme pour un LP, consiste à expliciter ce choix en amont et à mesurer ensuite la performance contre cet objectif, pas contre un benchmark unique.

A Annexe méthodologique

Cette annexe documente les hypothèses de calcul, les biais et les requêtes SQL de référence. Objectif, assurer une lecture transparente et un audit technique rapide.

1. Description du dataset

Source : CrunchBase (version académique, snapshot 2013). Tables utilisées : acquisitions.csv (9 562 lignes), investments.csv (~60 000 lignes), funding_rounds.csv (~22 000 lignes), objects.csv (~50 000 lignes). Période couverte : 2003–2013 (filtrage sur acquired_at). Base SQLite construite sous ADD#2/analysis.db pour toutes les jointures.

2. Définition des Top 10 VCs, volume dans dataset

Les Top 10 VCs sont définis par le nombre d'investments dans CrunchBase (2003–2013), non par leurs AUM ni leurs performances historiques. Cette définition est un proxy de taille et d'activité, pas de qualité. Les 10 investisseurs retenus :

#	VC	n investments	n startups
1	Intel Capital	529	383
2	New Enterprise Associates (NEA)	515	321
3	Sequoia Capital	507	309
4	SV Angel	484	441
5	Accel Partners	480	289
6	Y Combinator	478	459
7	Kleiner Perkins Caufield & Byers	478	271
8	Draper Fisher Jurvetson (DFJ)	462	274
9	500 Startups	364	315
10	First Round Capital	361	211

3. Tableau des biais identifiés

ID	Biais	Impact	Direction
B1	Sélection circulaire (reverse causality) Top VCs choisissent les meilleures startups ex ante.	Élevé	Surestime l'effet causal
B2	Biais survivant Faillites après levée : invisibles dans le dataset.	Élevé	Surestime taux & prix
B3	Biais reporting des prix 72,82 % manquants, petits deals non reportés.	Élevé	Surestime prix médians
B4	Absence lead investor CrunchBase ne distingue pas lead des co-investisseurs.	Moyen	Dilue l'effet Top VC
B5	Biais collecte post-2008 +147 % de données après 2008 (biais documentaire).	Moyen	Amplifie effets post-2008
B6	Proxy pedigree imparfait Top 10 par volume ≠ Top 10 par performance.	Moyen	Peut inclure VCs modestes

4. Requêtes SQL clés

G1, Taux d'exit Top VC vs marché

```
WITH top_ids AS (
    SELECT id
    FROM objects
    WHERE name IN (
        'Intel Capital',
        'New Enterprise Associates',
        'Sequoia Capital',
        'SV Angel',
        'Accel Partners',
        'Y Combinator',
        'Kleiner Perkins Caufield & Byers',
        'Draper Fisher Jurvetson (DFJ)',
        '500 Startups',
        'First Round Capital'
    )
),
startup_groups AS (
    SELECT
        i.funded_object_id AS object_id,
        CASE
            WHEN MAX(CASE WHEN i.investor_object_id IN (SELECT id FROM top_ids) THEN 1 ELSE 0 END) = 1
            THEN 'Top VC'
            ELSE 'Marche'
        END AS group_label
    FROM investments i
    GROUP BY i.funded_object_id
),
exits_2003_2013 AS (
    SELECT DISTINCT acquired_object_id AS object_id
    FROM acquisitions
    WHERE strftime('%Y', acquired_at) BETWEEN '2003' AND '2013'
)
SELECT
    sg.group_label,
    COUNT(*) AS n_startups_financed,
    SUM(CASE WHEN e.object_id IS NOT NULL THEN 1 ELSE 0 END) AS n_acquired,
    ROUND(100.0 * SUM(CASE WHEN e.object_id IS NOT NULL THEN 1 ELSE 0 END) / COUNT(*), 1) AS exit_rate_pct
FROM startup_groups sg
LEFT JOIN exits_2003_2013 e ON e.object_id = sg.object_id
GROUP BY sg.group_label;
```

G2, Délai médian d'exit, post-traitement pandas pour médiane

```
WITH top_ids AS (
    SELECT id
    FROM objects
    WHERE name IN (
        'Intel Capital',
        'New Enterprise Associates',
        'Sequoia Capital',
        'SV Angel',
        'Accel Partners',
        'Y Combinator',
        'Kleiner Perkins Caufield & Byers',
        'Draper Fisher Jurvetson (DFJ)',
        '500 Startups',
        'First Round Capital'
    )
),
group_labels AS (
    SELECT
        i.funded_object_id AS object_id,
        CASE
            WHEN MAX(CASE WHEN i.investor_object_id IN (SELECT id FROM top_ids) THEN 1 ELSE 0 END) = 1
            THEN 'Top VC'
            ELSE 'Marche'
        END AS group_label
    FROM investments i
    GROUP BY i.funded_object_id
),
min_funding AS (
    SELECT object_id AS funded_object_id, MIN(funded_at) AS first_funded_at
    FROM funding_rounds
    WHERE funded_at IS NOT NULL
    GROUP BY object_id
),
raw_delays AS (
    SELECT
        gl.group_label,
        a.acquired_object_id AS object_id,
        strftime('%Y', a.acquired_at) AS exit_year,
        (julianday(a.acquired_at) - julianday(mf.first_funded_at)) / 365.25 AS delay_years
    FROM acquisitions a
    JOIN group_labels gl ON gl.object_id = a.acquired_object_id
    JOIN min_funding mf ON mf.funded_object_id = a.acquired_object_id
    WHERE strftime('%Y', a.acquired_at) BETWEEN '2003' AND '2013'
)
SELECT group_label, object_id, exit_year, delay_years
FROM raw_delays
WHERE delay_years >= 0;
-- Post traitement pandas:
-- q = [0.25, 0.50, 0.75] avec interpolation='nearest'
-- stats = df.groupby('group_label')['delay_years']
--         .quantile(q, interpolation='nearest')
--         .unstack()
```

G3, Prix d'exit médian + percentiles

```
WITH top_ids AS (
    SELECT id
    FROM objects
    WHERE name IN (
        'Intel Capital',
        'New Enterprise Associates',
        'Sequoia Capital',
        'SV Angel',
        'Accel Partners',
        'Y Combinator',
        'Kleiner Perkins Caufield & Byers',
        'Draper Fisher Jurvetson (DFJ)',
        '500 Startups',
        'First Round Capital'
    )
),
group_labels AS (
    SELECT
        i.funded_object_id AS object_id,
        CASE
            WHEN MAX(CASE WHEN i.investor_object_id IN (SELECT id FROM top_ids) THEN 1 ELSE 0 END) = 1
            THEN 'Top VC'
            ELSE 'Marche'
        END AS group_label
    FROM investments i
    GROUP BY i.funded_object_id
),
min_funding AS (
    SELECT object_id AS funded_object_id, MIN(funded_at) AS first_funded_at
    FROM funding_rounds
    WHERE funded_at IS NOT NULL
    GROUP BY object_id
),
eligible AS (
    SELECT
        gl.group_label,
        a.acquired_object_id AS object_id,
        CAST(a.price_amount AS REAL) AS price_usd,
        (julianday(a.acquired_at) - julianday(mf.first_funded_at)) / 365.25 AS delay_years
    FROM acquisitions a
    JOIN group_labels gl ON gl.object_id = a.acquired_object_id
    JOIN min_funding mf ON mf.funded_object_id = a.acquired_object_id
    WHERE strftime('%Y', a.acquired_at) BETWEEN '2003' AND '2013'
)
SELECT group_label, object_id, price_usd
FROM eligible
WHERE delay_years >= 0
  AND price_usd > 0
  AND price_usd < 26000000000;
-- Post traitement pandas:
-- q = [0.50, 0.75, 0.90] avec interpolation='nearest'
-- stats = df.groupby('group_label')['price_usd']
--         .quantile(q, interpolation='nearest')
--         .unstack()
```

G4, Délai médian par VC, classement individuel

```
WITH top_names AS (
    SELECT name
    FROM objects
    WHERE name IN (
        'Intel Capital',
        'New Enterprise Associates',
        'Sequoia Capital',
        'SV Angel',
        'Accel Partners',
        'Y Combinator',
        'Kleiner Perkins Caufield & Byers',
        'Draper Fisher Jurvetson (DFJ)',
        '500 Startups',
        'First Round Capital'
    )
),
vc_investments AS (
    SELECT DISTINCT
        inv.name AS investor_name,
        i.funded_object_id AS object_id,
        i.funding_round_id
    FROM investments i
    JOIN objects inv ON inv.id = i.investor_object_id
    WHERE inv.name IN (SELECT name FROM top_names)
),
vc_first_round AS (
    SELECT
        vi.investor_name,
        vi.object_id,
        MIN(fr.funded_at) AS first_vc_funded_at
    FROM vc_investments vi
    JOIN funding_rounds fr ON fr.funding_round_id = CAST(vi.funding_round_id AS TEXT)
    WHERE fr.funded_at IS NOT NULL
    GROUP BY vi.investor_name, vi.object_id
),
base AS (
    SELECT
        vfr.investor_name,
        vfr.object_id,
        (julianday(a.acquired_at) - julianday(vfr.first_vc_funded_at)) / 365.25 AS delay_years
    FROM vc_first_round vfr
    JOIN acquisitions a ON a.acquired_object_id = vfr.object_id
    WHERE strftime('%Y', a.acquired_at) BETWEEN '2003' AND '2013'
)
SELECT DISTINCT investor_name, object_id, delay_years
FROM base
WHERE delay_years >= 0;
-- Post traitement pandas:
-- q = [0.25, 0.50, 0.75] avec interpolation='nearest'
-- stats = df.groupby('investor_name')['delay_years']
--         .quantile(q, interpolation='nearest')
--         .unstack()
```

G5, Prix médian par VC, classement individuel

```
-- Reutilise les CTE de G4 : top_names, vc_investments, vc_first_round
WITH eligible AS (
    SELECT
        vfr.investor_name,
        vfr.object_id,
        CAST(a.price_amount AS REAL) AS price_usd,
        (julianday(a.acquired_at) - julianday(vfr.first_vc_funded_at)) / 365.25 AS delay_years
    FROM vc_first_round vfr
    JOIN acquisitions a ON a.acquired_object_id = vfr.object_id
    WHERE strftime('%Y', a.acquired_at) BETWEEN '2003' AND '2013'
),
price_ready AS (
    SELECT DISTINCT investor_name, object_id, price_usd
    FROM eligible
    WHERE delay_years >= 0
      AND price_usd > 0
      AND price_usd < 26000000000
)
SELECT investor_name, object_id, price_usd
FROM price_ready;
-- Post traitement pandas:
-- q = [0.50, 0.75, 0.90] avec interpolation='nearest'
-- stats = df.groupby('investor_name')['price_usd']
--         .quantile(q, interpolation='nearest')
--         .unstack()
-- puis flag n<20
```

G6, Délai médian avant 2008 et après 2008 par groupe

```
-- Reutilise exactement les CTE de G2 : top_ids, group_labels, min_funding
WITH base AS (
    SELECT
        gl.group_label,
        CASE
            WHEN CAST(strftime('%Y', a.acquired_at) AS INT) < 2008 THEN 'Pre-2008'
            ELSE 'Post-2008'
        END AS periode,
        a.acquired_object_id AS object_id,
        (julianday(a.acquired_at) - julianday(mf.first_funded_at)) / 365.25 AS delay_years
    FROM acquisitions a
    JOIN group_labels gl ON gl.object_id = a.acquired_object_id
    JOIN min_funding mf ON mf.funded_object_id = a.acquired_object_id
    WHERE strftime('%Y', a.acquired_at) BETWEEN '2003' AND '2013'
)
SELECT group_label, periode, object_id, delay_years
FROM base
WHERE delay_years >= 0;
-- Post traitement pandas:
-- q = [0.25, 0.50, 0.75] avec interpolation='nearest'
-- stats = df.groupby(['group_label','periode'])['delay_years']
--         .quantile(q, interpolation='nearest')
--         .unstack()
```

5. Requêtes pandas clés

Cette section montre les étapes pandas structurantes du pipeline. La version exhaustive est documentée dans le fichier annexe technique ADD#2/appendix_pandas_full.md.

P1, Groupes Top VC vs marché

```
top_ids = pd.read_sql_query(
    "SELECT id FROM objects WHERE name IN ({})".format(','.join(['?']*len(top_vc_list))),
    conn, params=top_vc_list
)
top_id_set = set(top_ids['id'].tolist())

investments = pd.read_sql_query(
    "SELECT funded_object_id, investor_object_id FROM investments", conn
)
investments['is_top'] = investments['investor_object_id'].isin(top_id_set).astype(int)
group_labels = (
    investments.groupby('funded_object_id', as_index=False)['is_top']
    .max()
    .rename(columns={'funded_object_id': 'object_id'})
)
group_labels['group_label'] = group_labels['is_top'].map({1: 'Top VC', 0: 'Marche'})
```

P2, Base délai commune

```
acq = pd.read_sql_query(
    "SELECT acquired_object_id, acquired_at, price_amount FROM acquisitions", conn
).rename(columns={'acquired_object_id': 'object_id'})
acq['acquired_at_dt'] = pd.to_datetime(acq['acquired_at'], errors='coerce')
acq = acq[acq['acquired_at_dt'].dt.year.between(2003, 2013, inclusive='both')].copy()
acq['price_usd'] = pd.to_numeric(acq['price_amount'], errors='coerce')

min_funding = pd.read_sql_query(
    """
SELECT object_id, MIN(funded_at) AS first_funded_at
FROM funding_rounds
WHERE funded_at IS NOT NULL
GROUP BY object_id
""", conn
)
min_funding['first_funded_at_dt'] = pd.to_datetime(min_funding['first_funded_at'], errors='coerce')

base_delay = acq.merge(group_labels, on='object_id', how='inner').merge(
    min_funding[['object_id', 'first_funded_at_dt']], on='object_id', how='inner'
)
base_delay['delay_years'] = (base_delay['acquired_at_dt'] - base_delay['first_funded_at_dt']).dt.days / 365.25
base_delay = base_delay[pd.to_numeric(base_delay['delay_years'], errors='coerce') >= 0].copy()
```

P3, Métriques groupe (I1, I2, I3, I6)

```
def q_nearest(series, q):
    clean = pd.to_numeric(series, errors='coerce').dropna()
    return float(clean.quantile(q, interpolation='nearest')) if not clean.empty else 0.0

g2 = base_delay.groupby('group_label', as_index=False).agg(
    n=('delay_years', 'count'),
    median_years=('delay_years', lambda s: q_nearest(s, 0.50)),
    p25_years=('delay_years', lambda s: q_nearest(s, 0.25)),
    p75_years=('delay_years', lambda s: q_nearest(s, 0.75))
)

g3_base = base_delay[(base_delay['price_usd'] > 0) & (base_delay['price_usd'] < 26_000_000_000)].copy()
g3 = g3_base.groupby('group_label', as_index=False).agg(
    n_with_price=('price_usd', 'count'),
    median_usd=('price_usd', lambda s: q_nearest(s, 0.50)),
    p75_usd=('price_usd', lambda s: q_nearest(s, 0.75)),
    p90_usd=('price_usd', lambda s: q_nearest(s, 0.90))
)

g6_base = base_delay.copy()
g6_base['period'] = g6_base['acquired_at_dt'].dt.year.apply(lambda y: 'pre_2008' if y < 2008 else 'post_2008')
g6 = g6_base.groupby(['group_label', 'period'], as_index=False).agg(
    n=('delay_years', 'count'),
    median_delay_years=('delay_years', lambda s: q_nearest(s, 0.50)),
    p25=('delay_years', lambda s: q_nearest(s, 0.25)),
    p75=('delay_years', lambda s: q_nearest(s, 0.75))
)
```

P4, Métriques VC individuelles (I4, I5)

```
vc_investments = pd.read_sql_query(
    """
SELECT DISTINCT inv.name AS investor_name, i.funded_object_id AS object_id, i.funding_round_id
FROM investments i
JOIN objects inv ON inv.id = i.investor_object_id
WHERE inv.name IN ({})
""".format(','.join(['?']*len(top_vc_list))),
    conn, params=top_vc_list
)
vc_investments['funding_round_id_str'] = vc_investments['funding_round_id'].astype(str)

funding_rounds = pd.read_sql_query(
    "SELECT funding_round_id, funded_at FROM funding_rounds WHERE funded_at IS NOT NULL", conn
)
funding_rounds['funding_round_id_str'] = funding_rounds['funding_round_id'].astype(str)
funding_rounds['funded_at_dt'] = pd.to_datetime(funding_rounds['funded_at'], errors='coerce')

vc_rounds = vc_investments.merge(funding_rounds[['funding_round_id_str', 'funded_at_dt']], on='funding_round_id_str', how='inner')
vc_first_round = vc_rounds.groupby(['investor_name', 'object_id'], as_index=False)['funded_at_dt'].min().rename(columns={'funded_at
_dt': 'first_vc_funded_at_dt'})
vc_base = vc_first_round.merge(acq[['object_id', 'acquired_at_dt', 'price_usd']], on='object_id', how='inner')
vc_base['delay_years'] = (vc_base['acquired_at_dt'] - vc_base['first_vc_funded_at_dt']).dt.days / 365.25
vc_base = vc_base[pd.to_numeric(vc_base['delay_years'], errors='coerce') >= 0].copy()

g4 = vc_base.drop_duplicates(subset=['investor_name', 'object_id', 'delay_years']).groupby('investor_name', as_index=False).agg(
    n_exits=('delay_years', 'count'),
    median_delay_years=('delay_years', lambda s: q_nearest(s, 0.50)),
    p25=('delay_years', lambda s: q_nearest(s, 0.25)),
    p75=('delay_years', lambda s: q_nearest(s, 0.75))
).sort_values('median_delay_years', ascending=True)

g5_base = vc_base[(vc_base['price_usd'] > 0) & (vc_base['price_usd'] < 26_000_000_000)][['investor_name', 'object_id', 'price_usd']
].drop_duplicates()
g5 = g5_base.groupby('investor_name', as_index=False).agg(
    n_exits_with_price=('price_usd', 'count'),
    median_price_usd=('price_usd', lambda s: q_nearest(s, 0.50)),
    p75_usd=('price_usd', lambda s: q_nearest(s, 0.75)),
    p90_usd=('price_usd', lambda s: q_nearest(s, 0.90))
).sort_values('median_price_usd', ascending=False)
```

P5, Data coverage

```
n_observations_delay_analysis = int(len(base_delay))
n_top_vc_exits = int(len(base_delay[base_delay['group_label'] == 'Top VC']))
n_market_exits = int(len(base_delay[base_delay['group_label'] == 'Marche']))
n_with_price_top_vc = int(len(g3_base[g3_base['group_label'] == 'Top VC']))
n_with_price_market = int(len(g3_base[g3_base['group_label'] == 'Marche']))
price_missing_rate_pct = round(
    100.0 * (1 - (n_with_price_top_vc + n_with_price_market) / max(1, n_observations_delay_analysis)),
    2
)
```